



Desarrollo del portal e interfaz de TeresIA

1. DEFINICIÓN Y ALCANCE DE LOS TRABAJOS

El proyecto TeresIA pretende crear el portal digital TeresIA, que será un punto de acceso único a recursos terminológicos avanzados que permitan a los especialistas la posibilidad de crear, consultar y navegar por terminologías y sus términos de diferentes creadores y dominios. El objetivo principal de TeresIA es facilitar el acceso a datos terminológicos enlazados y a servicios avanzados de extracción y validación de términos en español. Para ello se contempla la creación de un portal web del proyecto bajo un estándar utilizado para portales de publicación de datos

El portal de terminología TeresIA constará de dos partes principales:

1. Un metabuscador y un catálogo de recursos terminológicos estructurados, y
2. Un conjunto de servicios de inteligencia artificial (IA) relacionados con funcionalidades terminológicas que también estarán a disposición de los usuarios registrados en el portal.




Figura 1. Estructura/Diagrama de bloques del proyecto TERESIA

El desarrollo del portal web del proyecto debe responder a una serie de funcionalidades específicas, que se alcanzarán mediante la implementación de al menos las siguientes tareas:

1. Desarrollo de un portal que implemente un metabuscador para un acceso unificado y común a terminologías de calidad en español y otras lenguas cooficiales. Este portal se desarrollará, en primera opción, bajo tecnologías de datos del portal OntoPortal (<https://ontoportal.org/>), dado que se trata de una aplicación de código abierto para la gestión de ontologías y datos semánticos y que incluye una arquitectura y funcionalidades básicas sobre las que se han desarrollado diferentes portales (AgroPortal, BioPortal, etc.). En el caso de que durante la fase de consultoría se determinase que esta alternativa no fuese viable o pudiese no serlo en la amplitud deseada se valoran otras alternativas. Por tanto, donde, a lo largo del documento, se expresa OntoPortal debe entenderse este portal u otra alternativa similar viable.
2. Desarrollar un metabuscador de términos, que permita recuperar los términos y toda aquella información asociada a los mismos procedentes de distintos proyectos terminológicos, diccionarios especializados, tesauros, etc., que se encuentren en el propio portal. Estos recursos serán previamente convertidos a los formatos de la web de datos y enlazados entre

ellos (esta tarea no le corresponde a la empresa, sino al equipo de investigación de TeresIA). Los datos se alojarán en el servidor del CSIC previsto, en la base de datos de Ontoportal que almacenará las terminologías, los términos y las URLs externas en los casos que se hayan detectado relaciones terminológicas con recursos externos a la plataforma.

3. Incorporar al metabuscador términos nuevos identificados tras los procesos de extracción de terminología (otro eje del trabajo de TeresIA) y convertidos a formatos de la web de datos.
4. Integrar un módulo que permita la revisión y edición colaborativa de las terminologías previamente extraídas mediante grupos de expertos de dominio encargados de su validación. El módulo será desarrollado por el equipo de TeresIA, pero este contrato ha de contemplar su integración en el portal.
5. Adaptar el sistema de gestión de usuarios de Ontoportal para el portal TeresIA mediante la asignación de roles y control de acceso. Entre los tipos de usuarios del portal habrá que contemplar los usuarios del metabuscador (de distinto tipo), los terminólogos y validadores que gestionarán el módulo descrito en el punto 4 y otros usuarios que quieran utilizar las herramientas de inteligencia artificial que se ofrecerán desde el portal (algoritmos desarrollados por el equipo de TeresIA).

Los portales generados a partir de OntoPortal ya cuentan con ciertas funcionalidades de gestión de recursos y búsqueda.

Metabuscador y catálogo de recursos terminológicos

El portal ofrecerá a cualquier usuario la posibilidad de navegar por los recursos terminológicos y los términos que se incluyen en el portal y que estén en abierto. Se podrán visualizar metadatos, términos y sus definiciones y propiedades. Aquellas terminologías que lo ofrezcan, dispondrán de descargas de los datos visualizables en formatos conocidos para la publicación de recursos tales como RDF, Turtle o CSV.

El metabuscador permitirá la búsqueda sencilla y avanzada (incluyendo filtros) sobre todos los recursos terminológicos disponibles en TeresIA o en una selección de los mismos. Las búsquedas se realizarán solo sobre los recursos terminológicos y términos recogidos en el portal TeresIA, mostrando la información relevante de los resultados obtenidos. Ontoportal cuenta con un metabuscador de base que realiza este tipo de búsquedas entre diferentes catálogos de datos. Otra visualización relevante que se plantea en el proyecto junto con la de Ontoportal es la de Skosmos (<https://skosmos.org/>), plataforma que visualiza vocabularios de datos. Se requerirá algo similar en la infraestructura Ontoportal.

Existirán diferentes perfiles de usuario que se podrán registrar en la plataforma, además de los perfiles de administradores que tendrán control total sobre la misma: usuario genérico sin registrar, usuario registrado básico, usuario registrado como productor de terminología, usuario registrado como moderador y/o validador y usuarios registrados con capacidad de administración.

Servicios de Inteligencia Artificial

Dentro del portal se incluirán servicios, algunos basados en inteligencia artificial, a disposición de los usuarios registrados. Estos servicios serán desarrollados por el equipo del proyecto TeresIA, no por la empresa. El papel de la empresa en este contrato al respecto de estos servicios será integrar dichos servicios dentro de la plataforma y verificar su correcto funcionamiento una vez integrados.

Algunos de estos servicios incluyen, entre otras, las actividades de extracción automática de terminología sobre un corpus, conversión de terminologías a datos enlazados, o enlace de terminologías generadas con otras existentes en el portal.

La infraestructura creada deberá permitir a los socios del proyecto TeresIA generar terminologías en el ámbito jurídico y/o médico, enriquecer terminologías existentes y validarlas mediante expertos, como escenarios de uso tipo que se puedan extender a otros ámbitos. Las nuevas terminologías creadas serán otro insumo más del metabuscador. A través del metabuscador se debe poder buscar a través de los nuevos términos generados por el proyecto TeresIA. A modo de demostración de las bondades del portal y de los beneficios de las terminologías creadas, éstas deberán poder ser volcadas en el portal para su gestión, publicación y recuperación de contenidos.

Desde un punto de vista de gobernanza del dato, el portal actuará como puerta de entrada a la terminología en España, pero respetando las licencias de uso de los recursos disponibles en este. Además, el portal dispondrá de capacidades de registro y gestión de usuarios con diferentes niveles de privilegio, quedando las funcionalidades de consulta de datos totalmente abiertas y las de adición, validación y gestión (validación/sanción) de recursos, limitadas a usuarios específicos adecuadamente identificados. Para facilitar la actualización y mantenimiento de las herramientas se utilizarán, en la medida de lo posible, librerías de código abierto.

En cualquier caso, con fines de seguridad y recuperación se garantizará la trazabilidad de toda la actividad de los usuarios que requieran de registro, más allá del simple control de acceso.

2. REQUISITOS FUNCIONALES

Se contemplan los siguientes requisitos funcionales, que habrán de ser afianzados o remodelados a partir del trabajo conjunto entre la empresa y el equipo de TeresIA:

- Desarrollo de un portal sobre la tecnología de Ontoportal que implemente un metabuscador para un acceso unificado y común a terminologías de calidad del español y lenguas cooficiales que se dará de alta en este portal. Ontoportal ya cuenta con herramientas de buscador, gestión de recursos y catálogos.
- Metabuscador de términos, que permita recuperar los términos y la información asociada a los mismos, procedentes de las distintas terminologías registradas en el portal.
- Sistema de ingesta y publicación de datos. En el portal, un usuario registrado, que haya sido previamente validado, podrá subir al catálogo su terminología y esta será publicada dentro del catálogo. Como catálogo se concibe el conjunto de terminologías y términos indexados dentro del portal. Las terminologías subidas serán convertidas a los formatos de la web semántica.
- Sistema de inteligencia artificial para la extracción automática de terminologías. Un usuario puede subir un corpus al portal y utilizar herramientas de IA para la extracción de términos. Esta nueva terminología podrá también guardarse en el portal aunque no estará pública para

todos los usuarios. La podrá compartir con otros usuarios como si fuese un 'proyecto' en construcción o pendiente de validación o sanción. El usuario podrá mejorarla, revisarla, enriquecerla y, en algún momento, hacerla pública para que se registre dentro del catálogo completo del portal. El software de extracción de términos por IA (basado en distintos algoritmos configurables) será proporcionado por los socios del proyecto.

- Servicios de IA para el enriquecimiento de las terminologías. Dentro de una terminología en construcción, por uno o varios usuarios (trabajo colaborativo), además del servicio de extracción de terminología por IA, se deben dar cabida a otros servicios que permitan enriquecer las terminologías como las siguientes: extracción automática de relaciones entre términos, desambiguación y enlazado de términos, conversión de la terminología a formatos de la web semántica. Todos estos servicios serán proporcionados por los socios del proyecto para su integración en el portal.
- Sistema de validación y sanción de terminologías por expertos. El portal prevé la integración de un módulo desarrollado por el equipo de TeresIA que permita la revisión y edición colaborativa de las terminologías extraídas a grupos de expertos de dominio debidamente identificados y registrados para su sanción. El módulo será proporcionado por los socios del proyecto. La gestión de los usuarios de este módulo deberá realizarse mediante el propio portal.
- Gestión de usuarios. El portal prevé la gestión de varios tipos y perfiles de usuarios con distintos niveles de acceso. Será obligatorio proporcionar un sistema de trazabilidad para las actividades de los usuarios registrados más allá del simple control de acceso.

3. REQUISITOS NO FUNCIONALES

Durante la ejecución del proyecto, la primera tarea de la empresa será la toma de requisitos no funcionales para el desarrollo del portal web de TeresIA requeridos por los diferentes socios del proyecto. Algunos de estos requisitos son:

1. Rendimiento y Escalabilidad:

El portal debe ser capaz de manejar cargas concurrentes de como mínimo 30 usuarios sin degradación del rendimiento respecto a un único usuario. Se plantea que no habrá una carga simultánea de más de 100 usuarios.

Tiempos de respuesta para la presentación de resultados de la consulta realizada por un usuario inferior a 1 segundo para menos de 100 resultados y tiempo para mostrar información para un resultado concreto de 5 segundos en el 95 % de los casos. Asimismo, se requiere la implementación de sistemas de optimización para todos aquellos casos en los que se superen bien el número de 100 resultados por consulta o bien cuando por razones de su ubicación la información se prevea que esta no esté disponible en los servidores del Centro o centros colaboradores.

2. Seguridad

Aplicará un sistema de autenticación robusto y fiable y cuando sea preciso interactuar con otras Web utilizará autorización mediante OAuth 2.0 o equivalente.

Durante el desarrollo utilizarán estrategias y estructuras que integrándose en los sistemas propios del Centro permitan maximizar la protección contra ciberataques en un futuro.

Implementará un Registro de control de accesos que en conjunción con un sistema de auditoría permita detectar usos indebidos.

3. Disponibilidad y Fiabilidad

Para garantizar una alta disponibilidad se implementarán sistemas automatizados y programables de ejecución de backups tanto en MySQL, como en AllegroGraph y 4store.

Asimismo, se implementarán sistemas de comprobación automatizados que permitan controlar y evidenciar la fiabilidad de la aplicación a la hora de proporcionar los resultados solicitados por los usuarios.

4. Interoperabilidad

Se requiere que las API REST sean diseñadas siguiendo con estándares, a poder ser internacionales, para facilitar la integración con otros sistemas y se garantizará la compatibilidad de estas con formatos JSON, RDF, SPARQL y XML para alcanzar la interoperabilidad con otros sistemas semánticos.

Asimismo, se requiere que los resultados de las consultas y todos aquellos datos e información relevante sobre la misma puedan ser exportados e importados desde formatos estandarizados (CSV, TTL, JSON-LD).

5. Trazabilidad:

Con fines de recuperación y aseguramiento de la consistencia de los datos, se gestionarán y controlarán todas aquellas actividades de los usuarios registrados que se consideren sensibles para el sistema.

4. REQUISITOS TÉCNICOS

En esta sección se detallan las herramientas principales necesarias para el desarrollo del portal. El portal de datos se basará en la tecnología OntoPortal (<https://ontportal.org/>), plataforma de código abierto para la gestión de ontologías y datos semánticos. Sobre esta base, se desarrollarán cuantas funcionalidades adicionales sean necesarias para alcanzar los objetivos del proyecto.

A continuación, se detallan algunos de los componentes del entorno tecnológico que se han de tener en cuenta para el objeto del contrato.

1. Infraestructura Tecnológica

Bases de datos:

- AllegroGraph: Base de datos RDF.
- Apache Jena Fuseki: Base de datos RDF.
- Virtuoso: Base de datos RDF.
- Elasticsearch: Indexación y búsqueda de datos documentales.
- MongoDB: Base de datos NoSQL.

Servidores y despliegue:

Uso de contenedores y virtualización con Docker. Se podrá plantear el uso de Kubernetes para la gestión de contenedores siempre y cuando se garantice la misma y su integración con el resto de componentes del sistema.

2. Backend

Se detallan a continuación una serie de herramientas y los usos aceptados para las mismas:

- de Java: Desarrollo de lógica de negocio y gestión del modelo de datos.
- Node.js: Servicios backend, APIs y procesamiento en tiempo real.
- APIs RESTful para la comunicación componentes.

Se contempla el uso de Frameworks para la organización e implementación de los lenguajes para desarrollos tales como SpringBoot.

3. Visualización y Frontend

Se detallan a continuación una serie de herramientas y los usos aceptados para las mismas:

- JavaScript: Desarrollo de interfaces dinámicas e interactivas.
- Java: Aplicaciones de visualización de datos e integración con modelos backend.
- Ruby: Desarrollo de herramientas auxiliares y scripting para procesamiento de datos.

4. Interfaz y usabilidad:

En ellos se utilizarán diseños adaptables, accesibles y configurables basados en estándares web.

5. Integración y Extensibilidad

En la medida de lo posible se aplicará el desarrollo mediante APIs RESTful para garantizar la interoperabilidad con otros sistemas. Y cuando la aplicación de estos desarrollos no pueda ser aplicada se garantizará y demostrará en ellos esta interoperabilidad.

Ontoportail cuenta con documentación sobre su entorno y los diferentes componentes que componen su arquitectura base: https://ontoportail.github.io/documentation/docs/developers-docs/global_architecture/

5. PLAZOS

Los trabajos deberán realizarse en un plazo máximo de 6 meses a contar desde la adjudicación. Se acordará con la empresa un calendario de hitos y entregables para el pago progresivo en función de las entregas.